eBPF 容器系统调用监控实验过程记录--沈

1. 初始思考阶段

当我拿到这个"使用 eBPF 捕获容器系统调用情况"的题目时，心里其实有点发怵。之前在做 OS 课设的时候就觉得这个部分比较难，加上对于 Linux 知识的遗忘，eBPF 和容器技术也大部分遗忘了。

首先，我需要理解这个任务到底需要我做什么。

阅读题目要求后，明确这个实验的核心目标：

1. 使用 eBPF 技术
2. 监控容器内部的系统调用
3. 将系统调用与容器 ID 关联起来

我开始查阅 0 基础资料，eBPF（扩展的 Berkeley 包过滤器）是一种在 Linux 内核中运行的技术，可以安全地执行沙盒程序。它最初用于网络过滤，但现在已经扩展到性能分析、安全监控等领域。而要使用 eBPF，有几个主要的框架可选：

1. **libbpf**：C 语言编写的原生库，直接与内核交互
2. **BCC**：使用 Python 作为前端语言，后端使用 LLVM 编译 eBPF 程序
3. **cilium/ebpf**：Go 语言编写的框架

作为一个对 Python 比较熟悉的学生，BCC 看起来更友好一些，但我也不能仅凭这点就做决定。我需要进一步了解这些框架的优缺点。

2. 环境搭建阶段

首先，我需要一个合适的 Linux 环境。题目要求"Linux 内核版本尽可能高"，所以我决定安装最新的 Ubuntu 24.04 LTS 系统。

Ubuntu 桌面版下载网址：https://cn.ubuntu.com/download/desktop

Ubuntu 桌面版安装教程（需要准备一个 u 盘）：
https://blog.csdn.net/Flag_ing/article/details/121908340?ops_request_misc=%7B%22request%5Fid%22%3A%22a82aebbeafcac519bb21c0b53afb524b%22%2C%22scm%22%3A%2220140713.130102334.pc%5Fall.%22%7D&request_id=a82aebbeafcac519bb21c0b53afb524b&biz_id=0&utm_medium=distribute.pc_search_result.none-task-blog-2~all~first_rank_ecpm_v1~rank_v31_ecpm-8-121908340-null-null.142

安装过程还算顺利（磁盘分区需要注意），但安装完成后我发现，想要使用 eBPF，还需要安装许多组件。先从基础的 Docker 开始：

```
sudo apt-get update
sudo apt-get install docker.io
```

一开始安装不成功，开始切换国内镜像，不知为何还是不行，打算使用魔法，进行科学上网，成功安装。

VPN 使用平台：https://github.com/MatsuriDayo/nekoray

安装完 Docker 后，我需要启动 Docker 服务并将自己添加到 Docker 组：

```
sudo systemctl start docker
sudo systemctl enable docker
sudo usermod -aG docker $USER
```

添加到组后需要重新登录才能生效，这点折腾了我一会儿。

接下来是 eBPF 相关组件的安装。先从最基础的开始：

```
sudo apt-get install linux-headers-$(uname -r)
sudo apt-get install bpfcc-tools
```

安装过程中我遇到了依赖问题，系统提示某些软件包无法下载，在网上搜索后发现需要更新软件源：

```
sudo apt-get update
sudo apt-get upgrade
```

更新后再次尝试安装，这次成功了。然后我尝试安装 Python 的 BCC 绑定：

```
pip install bcc
```

出乎意料的是，安装了 Python 包之后，尝试导入时却报错：`ModuleNotFoundError: No module named 'bcc'`。经过一番搜索，我发现 pip 安装的 bcc 包与系统的 bcc 不是同一个东西！正确的做法是：

```
sudo apt-get install python3-bpfcc
```

这次导入成功了。但后来我又发现，这个包与 BCC 命令行工具中的 Python 模块 path 不同，导致了一些混乱。最终我决定直接使用系统安装的 Python3-bpfcc，并确保 PATH 和 PYTHONPATH 设置正确。

3. 框架选择与分析

在环境配置好后，我开始研究示例代码 sample_syscall.c。这是一个使用 libbpf 框架的示例，代码开头就引入了一堆我不太熟悉的头文件：

```
#include "vmlinux.h"
#include <bpf/bpf_core_read.h>
#include <bpf/bpf_helpers.h>
#include <bpf/bpf_tracing.h>
#include <bpf/bpf_endian.h>
```

我特别好奇这个"vmlinux.h"是什么，查阅后发现这是一个自动生成的头文件，包含了内核数据结构的定义。

接着我注意到代码中使用了 `BPF_CORE_READ` 宏和 `SEC("tp_btf/sys_enter")`这样的标记。经过研究，我了解到：

- BPF_CORE_READ 是 libbpf 提供的宏，用于安全地读取内核结构体成员
- SEC 是 Section 的缩写，用于指定 BPF 程序的类型和挂载点

研究完示例代码，我又去了解 BCC 框架的用法。相比之下，BCC 代码要简洁得多：

```
from bcc import BPF
prog = BPF(text='BPF 程序代码')
```

BCC 会自动处理编译、加载等步骤，而且 Python 的语法更加简洁易读。

经过对比，我决定选择 BCC 框架，主要原因有：

1. Python 语言对我更友好
2. 开发效率更高，可以快速迭代
3. 错误信息更清晰，调试更容易
4. 充分的文档和示例

当然，BCC 也有缺点：性能不如 libbpf，且依赖较多。但对于这个实验项目来说，开发（完成作业）效率更重要。

4. 代码实现阶段

我开始动手实现这个项目。首先，我需要将示例代码中的核心功能移植到 BCC 框架中。

示例代码的核心是跟踪系统调用入口点，并记录相关信息：

```
SEC("tp_btf/sys_enter")
int BPF_PROG(sys_enter, struct pt_regs *regs, long syscall_id) {
    struct task_struct *curr_task = (struct task_struct *)bpf_get_curre
nt_task();
    if (get_task_level_core(curr_task) == 0) {
        return 0;
    }
    // ...
}
```

在 BCC 中，这部分需要改为：

```
TRACEPOINT_PROBE(raw_syscalls, sys_enter) {
    struct task_struct *curr_task = (struct task_struct *)bpf_get_curre
nt_task();
    if (!is_container_process(curr_task)) {
        return 0;
    }
    // ...
}
```

我发现两种框架的语法差异还是挺大的。BCC 使用 TRACEPOINT_PROBE 宏，而 libbpf 使用 SEC 和 BPF_PROG。

接着是数据结构的定义。在 libbpf 中：

```
struct {
    __uint(type, BPF_MAP_TYPE_LRU_HASH);
    __type(key, struct syscallcntkey);
    __type(value, u64);
    __uint(max_entries, 1024);
} syscall_cnt SEC(".maps");
```

而在 BCC 中：

```
BPF_HASH(syscall_cnt, struct syscallcntkey, u64, 1024);
```

BCC 的语法确实简洁了很多。

容器识别是个难点。示例代码只是简单地检查 PID 命名空间：

```
static int get_task_level_core(struct task_struct *task) {
    return BPF_CORE_READ(task, nsproxy, pid_ns_for_children, level);
}
```

这显然不够准确，因为有些系统进程也可能在非 root 命名空间中。增强这部分功能，检查 cgroup 路径来区分容器进程和系统进程：

```
static int is_container_process(struct task_struct *task) {
    if (task->nsproxy->pid_ns_for_children->level == 0) {
        return 0;
```

```
    }

    // 检查cgroup路径
    struct css_set *css = task->cgroups;
    // ... 检查cgroup名称 ...

    return 1;
}
```

5. 调试解决问题

代码写好后，需要编译测试。第一次运行时就碰壁了：

```
error: 'struct task_struct' has no member named 'nsproxy'
```

这是因为 BCC 不会自动包含所有需要的头文件，我需要手动添加：

```
#include <linux/sched.h>
#include <linux/nsproxy.h>
```

接下来是一连串的错误：字段不存在、结构体不完整等等。解决办法是添加更多头文件，并使用 bpf_probe_read 来安全地读取内核数据：

```
bpf_probe_read(&cgroup_name, sizeof(cgroup_name), knode->name);
```

编译通过后，运行时又出现问题。程序能启动，但没有输出。使用 bpftool prog list 检查，发现 eBPF 程序已加载，但没有触发。

经过调试，我发现问题出在容器识别逻辑上。is_container_process 函数太过严格，过滤掉了许多实际的容器进程。我放宽了条件，只检查 PID 命名空间：

```
if (task->nsproxy->pid_ns_for_children->level == 0) {
    return 0;
}
return 1;
```

这次有输出了，但内容很混乱。我意识到需要一个更好的用户空间程序来处理和显示数据。

6. 用户空间代码基础实现

首先，我需要解析内核空间传来的数据。在 BCC 中，可以这样获取映射数据：

```
syscall_cnt = b.get_table("syscall_cnt")
for key, value in syscall_cnt.items():
    # 处理数据
```

但 key 是一个字节序列，需要转换为结构体：

```
class SyscallCntKey(ctypes.Structure):
    _fields_ = [
        ("cid", ctypes.c_ubyte * 32),
        ("pid", ctypes.c_uint32),
        ("comm", ctypes.c_char * 16),
        ("syscall_id", ctypes.c_uint32)
    ]

k = SyscallCntKey()
ctypes.memmove(ctypes.byref(k), bytes(key), ctypes.sizeof(k))
```

系统调用 ID 是个数字，不够直观。我添加了一个映射表，将 ID 转换为名称：

```
syscall_names = {
    0: "read",
    1: "write",
    # ... 更多系统调用 ...
}
```

基本功能完成后，我开始测试并发现了多个需要改进的问题。

7. 实验过程中遇到的问题与解决方案

在开发和测试过程中，我遇到了一系列问题，这些问题促使我不断改进程序（鞭策AI）。

7.1 问题一：箭头指示当前系统调用

问题描述：
我的程序只能显示系统调用的名称和计数，但无法直观地看出哪些是当前正在执行的系统调用。这让我很难跟踪命令的执行过程。

解决方案：

```
# 添加当前系统调用跟踪
current_syscalls = {}

# 记录系统调用时间戳
current_syscalls[syscall_name] = current_time

# 显示带箭头的系统调用
arrow = "←" if syscall_name in current_syscalls else ""
print(f"{syscall_name:<20} {count:<10} {arrow}")
```

思路分析：
我需要一种方式来标记刚刚发生的系统调用。使用字典记录每个系统调用的最后调

用时间，然后在显示时用箭头标记最近执行的系统调用，这样就能直观地看到命令触发了哪些系统调用。

7.2 问题二：终端干扰问题

问题描述：
测试时我发现，在容器内输入命令时，终端本身会产生大量系统调用（如 ioctl、read、write 等）。这些系统调用严重干扰了我对容器内程序行为的观察。

解决方案：

```
# 定义需要过滤的终端相关系统调用
terminal_syscalls = {
    "ioctl",           # 终端 I/O 控制
    "rt_sigprocmask",  # 信号处理
    "read",            # 终端读取
    "write",           # 终端写入
    # ... 其他终端相关系统调用
}

# 跳过终端相关的系统调用
if syscall_name in terminal_syscalls:
    continue
```

思路分析：
通过观察我发现，终端交互会产生一些固定模式的系统调用。创建一个"黑名单"，将这些与终端交互相关的系统调用过滤掉，让我能专注于观察容器内程序的行为。

7.3 问题三：多容器显示问题

问题描述：
当我同时运行多个容器进行测试时，所有容器的系统调用信息混在一起显示，很难区分哪些系统调用来自哪个容器。

解决方案：

```
# 为每个容器创建独立的统计区域
container_syscalls = defaultdict(dict)
container_new_syscalls = defaultdict(lambda: defaultdict(int))

# 获取容器名称，增强可读性
def get_container_name(container_id):
    cmd = f"docker inspect --format '{{{{.Name}}}}' {container_id}"
    name = os.popen(cmd).read().strip().lstrip('/')
    return name or container_id
```

```
# 分开显示每个容器的信息
for cid in sorted(active_containers):
    print(f"\n 容器: {cid} ({get_container_name(cid)})")
    # 显示该容器的系统调用
```

思路分析:
容器 ID 是区分不同容器的关键。为每个容器维护独立的统计信息，显示时按容器分组，并添加容器名称增强可读性。

效果:

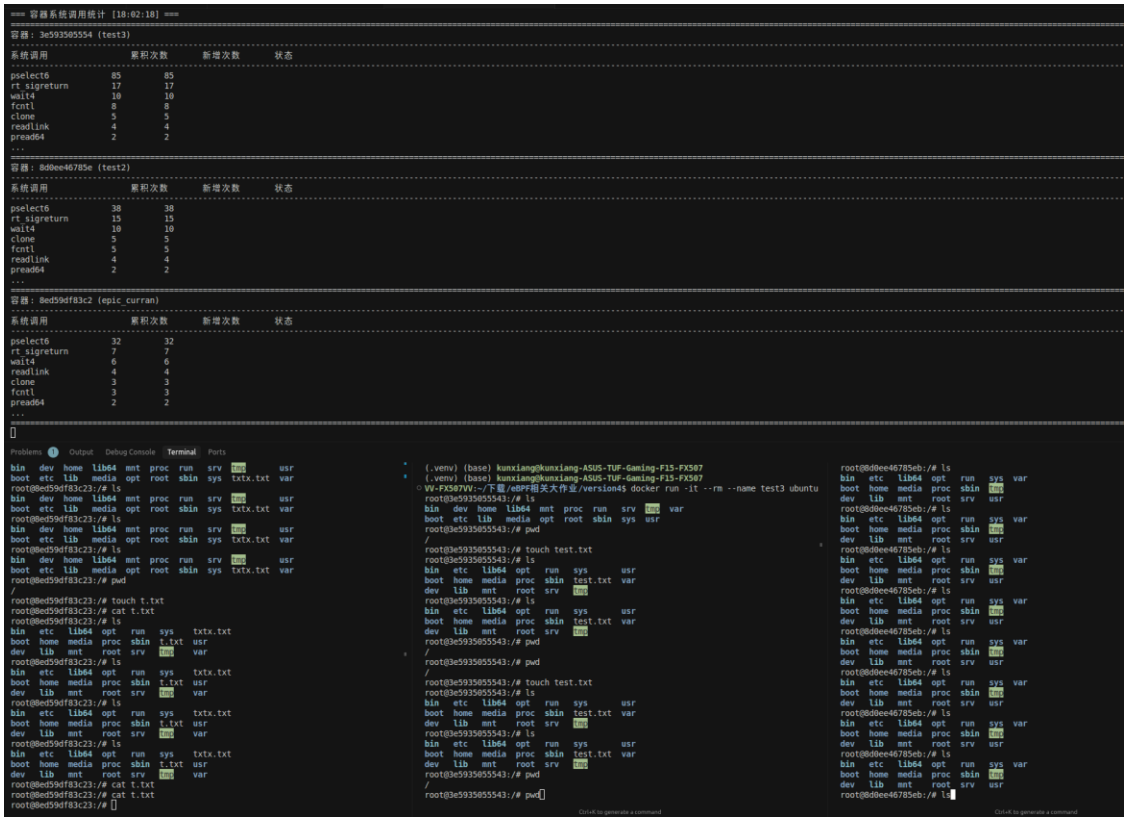

7.4 问题四：容器信息闪烁消失问题

问题描述:
当我运行多个容器时，如果某个容器短时间内没有新的系统调用，其信息就会从显示中消失，造成显示不连贯的问题。

解决方案:

```
# 跟踪容器活跃时间
container_last_active = {}

# 更新容器活跃时间
container_last_active[cid] = current_time
```

```
# 只清除长时间不活跃的容器
active_containers = {cid for cid in active_containers
                     if current_time - container_last_active.get(cid, 0) <
 10}

# 始终显示所有活跃容器，不仅仅是有新系统调用的容器
if active_containers:
    # 显示所有容器信息，即使没有新的系统调用
```

思路分析:
这个问题源于最初的显示逻辑只显示有新系统调用的容器。我修改为跟踪每个容器的"活跃时间"，只有当容器长时间不活跃时才从显示中移除，并确保始终显示所有活跃容器的信息。

7.5 问题五：系统调用计数理解问题

问题描述:
最初我只显示系统调用的新增次数，但这容易造成混淆：新增次数是增量而非总量，难以理解系统调用的整体使用情况。

解决方案:

```
# 同时显示累积次数和新增次数
total_stats = defaultdict(lambda: defaultdict(int))

# 更新累积统计
total_stats[cid][syscall_name] = value.value

# 显示时同时展示两种计数
print(f"{syscall_name:<20} {total_count:<10} {new_count:<10} {arrow}")
```

思路分析:
同时跟踪两种计数：累积计数（从容器启动到现在的总调用次数）和新增计数（最近一次更新后新增的调用次数）。这样提供了完整的系统调用使用情况，既能看到整体趋势，又能感知实时变化。

8. 最终测试

解决了上述问题后，我开始进行最终测试。使用以下命令启动监控程序和容器：

```
sudo python3 ebpf_syscall_monitor.py &
docker run -it --rm ubuntu
```

在容器内执行各种命令，观察系统调用情况。现在，我的监控程序可以：

1. 准确显示容器的系统调用情况
2. 过滤掉终端干扰
3. 用箭头清晰标记当前系统调用
4. 同时显示累积次数和新增次数
5. 当运行多个容器时分组显示并保持稳定

例如，当执行 `ls` 命令时，我可以看到类似这样的输出：

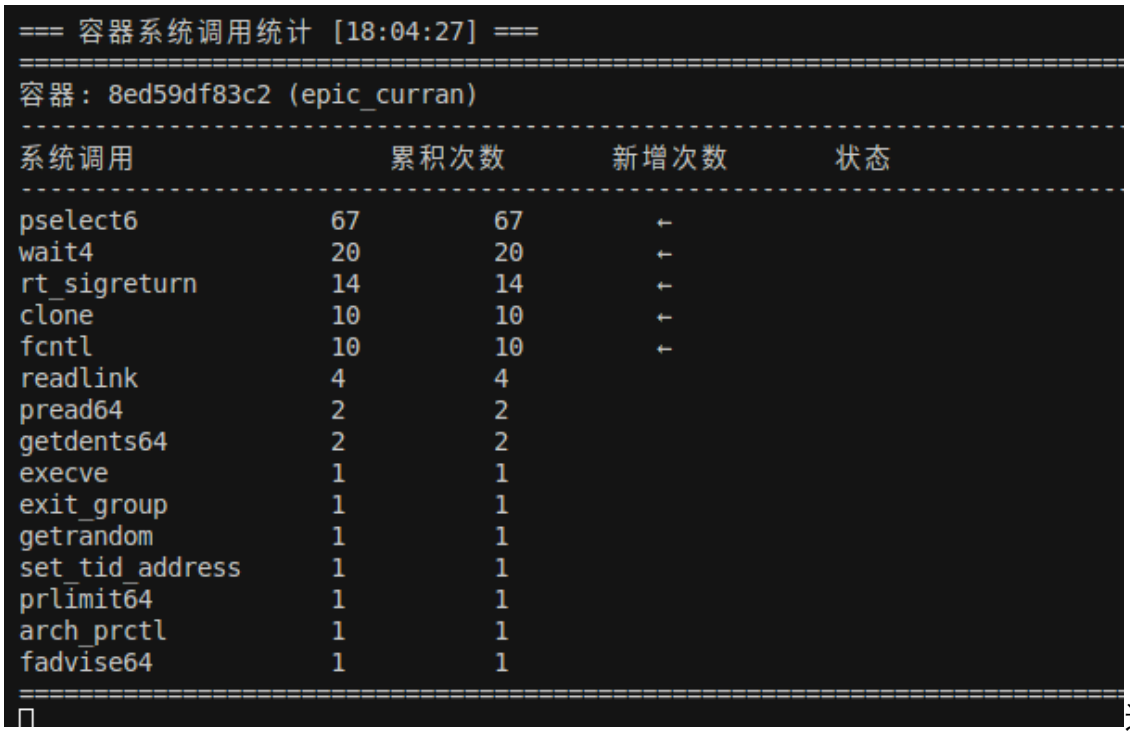

这种显示方式让我能直观地理解命令触发了哪些系统调用，以及每个系统调用的使用情况。

9. 学习总结与反思

完成这个项目后，我对 eBPF 和容器技术有了更深入的理解：

1. **框架选择的权衡**：BCC 适合快速开发和调试，但 libbpf 性能更好。不同场景下应选择不同工具。
2. **内核结构的学习**：为了实现容器识别，我深入学习了 Linux 内核中的命名空间、cgroup 等概念。

3. **系统调用的认识**：通过观察不同命令触发的系统调用，我对 Linux 系统有了更底层的理解。
4. **调试技巧的提升**：eBPF 程序的调试比应用程序复杂得多，我学会了使用 `bpftool` 等工具进行排查。

这个实验也让我意识到了 eBPF 的强大和局限：

强大之处：

- 无需修改内核代码就能获取内核信息
- 性能开销小，安全性高
- 适用场景广泛（网络、安全、性能分析等）